Perfis de abastecimento de água e esgotamento sanitário dos municípios do estado de São Paulo: uma análise de clusterização comparativa entre 2019 e 2024

Camila Alves Teixeira da Silva[1], **Carolina Numata Pereira**[1], **Thaís de Lima Peixoto**[1]

[1]Escola de Artes, Ciências e Humanidades – Universidade de São Paulo (USP)
São Paulo – SP – Brasil

camila.atsilva@usp.br, carolinanumata@usp.br, tpeixoto@usp.br

Resumo. *O acesso aos serviços de abastecimento de água e de esgotamento sanitário apresenta distribuição desigual entre os territórios. Este trabalho tem como objetivo identificar e caracterizar perfis desses serviços nos municípios do estado de São Paulo, comparando dois cortes temporais, 2019 e 2024, e relacionando os perfis ao porte populacional. São utilizados dados do Sistema Nacional de Informações sobre Saneamento (SNIS), referentes a 2019, e do Sistema Nacional de Informações em Saneamento Básico (SINISA), referentes a 2024. Após a harmonização das bases, foram selecionados quatro indicadores comparáveis entre os sistemas: atendimento total de água, perdas na distribuição, atendimento total de esgoto e tratamento do esgoto coletado. Após a exclusão de valores implausíveis, a amostra principal reúne 597 dos 645 municípios com os quatro indicadores nos dois anos. Resultados preliminares com k-means indicam três perfis, que combinam níveis de acesso às redes e de tratamento do esgoto e se distribuem de forma graduada segundo o porte. A pesquisa adota abordagem quantitativa, de natureza aplicada e objetivos exploratórios e descritivos. Serão comparados três algoritmos de clusterização: k-means, agrupamento hierárquico de Ward e modelo de mistura gaussiana, com validação por métricas internas, concordância entre algoritmos, reamostragem bootstrap e plausibilidade dos perfis.*

Abstract. *Access to water supply and sewage services is unevenly distributed across territories. This study aims to identify and characterize profiles of these services in the municipalities of the state of São Paulo, comparing two time points, 2019 and 2024, and relating the profiles to population size. Data from the National Sanitation Information System (SNIS), for 2019, and from the National Basic Sanitation Information System (SINISA), for 2024, are used. After harmonizing the databases, four indicators comparable between the systems were selected: total water service coverage, distribution losses, total sewage collection coverage and treatment of collected sewage. After excluding implausible values, the main sample comprises 597 of the 645 municipalities with all four indicators in both years. Preliminary k-means results indicate three profiles that combine levels of network access and sewage treatment and are distributed in a graded way across population size classes. The research adopts a quantitative approach, with an applied nature and exploratory and descriptive objectives. Three clustering algorithms will be compared: k-means, Ward's hierarchical clustering and Gaussian mixture models, validated through internal*

metrics, agreement between algorithms, bootstrap resampling and plausibility checks.

1. Introdução

O saneamento básico constitui um dos principais componentes da infraestrutura urbana e desempenha papel fundamental na promoção da saúde pública, na preservação ambiental e na qualidade de vida da população. O acesso adequado aos serviços de abastecimento de água e de esgotamento sanitário está relacionado às condições de vida da população e à capacidade de planejamento e gestão dos territórios. Apesar da expansão desses serviços observada no Brasil, a disponibilidade e as condições de atendimento ainda apresentam diferenças entre municípios e regiões, tornando relevante a análise de sua distribuição territorial.

No estado de São Paulo, essa questão apresenta particularidades decorrentes da grande diversidade existente entre seus municípios. O estado reúne municípios com diferentes dimensões populacionais, características territoriais, estruturas econômicas e formas de organização dos serviços públicos. Dessa maneira, uma análise baseada exclusivamente em indicadores agregados para todo o estado pode ocultar diferenças existentes entre os municípios. A observação conjunta de diferentes indicadores permite investigar como essas características se combinam e identificar municípios que apresentam padrões semelhantes.

A análise de múltiplas variáveis também é relevante porque diferentes dimensões da infraestrutura podem apresentar comportamentos distintos dentro de um mesmo município. Um município pode, por exemplo, apresentar elevada cobertura de abastecimento de água e, simultaneamente, baixa proporção de esgoto tratado ou perdas elevadas na distribuição. Dessa forma, a análise individual de indicadores pode não ser suficiente para representar a configuração geral dos serviços. A identificação de perfis permite considerar simultaneamente diferentes características e observar combinações recorrentes entre os municípios.

Nesse contexto, técnicas de aprendizado de máquina não supervisionado, especialmente os métodos de clusterização, constituem uma alternativa para identificar grupos de unidades com características semelhantes, sem que seja necessário estabelecer previamente quais municípios pertencem a cada grupo. A utilização de diferentes algoritmos é importante para avaliar a consistência dos agrupamentos, pois métodos distintos podem produzir soluções diferentes em função de seus pressupostos. Nesta pesquisa, são comparados o k-means, o agrupamento hierárquico de Ward e o modelo de mistura gaussiana, representando abordagens particional, hierárquica e probabilística.

Outro aspecto central é a comparação entre 2019, com dados do Sistema Nacional de Informações sobre Saneamento (SNIS), e 2024, com dados do Sistema Nacional de Informações em Saneamento Básico (SINISA). Como o período envolve a substituição de um sistema de informação pelo outro, a utilização conjunta das bases exige uma etapa de harmonização que identifique indicadores efetivamente comparáveis. Essa etapa levou à delimitação do escopo aos serviços de abastecimento de água e esgotamento sanitário: os indicadores de resíduos sólidos disponíveis nas duas bases apresentaram diferenças de definição e de população de referência que comprometem a comparação entre os anos (Seção 2.2.1).

A literatura demonstra a relevância da análise das desigualdades territoriais em saneamento e o potencial da clusterização para identificar grupos de municípios semelhantes [Raupp et al. 2017, Lima e Moreira 2025, Lima et al. 2022], conforme discutido na Seção 3.

Diante desse contexto, o objetivo deste trabalho é identificar e caracterizar perfis de abastecimento de água e esgotamento sanitário dos municípios do estado de São Paulo por meio de técnicas de clusterização, utilizando dados referentes a 2019 e 2024. Busca-se, especificamente: (i) identificar agrupamentos de municípios com características semelhantes; (ii) comparar os resultados produzidos por diferentes algoritmos; (iii) investigar diferenças entre os perfis observados nos dois cortes temporais; e (iv) verificar como os perfis se distribuem segundo o porte populacional dos municípios.

2. Metodologia

Esta pesquisa adota uma abordagem aplicada, na medida em que busca fornecer subsídios práticos para o diagnóstico das condições de saneamento nos municípios do estado de São Paulo [Gil 2017]. Quanto aos objetivos, o trabalho assume caráter simultaneamente exploratório e descritivo [Mohajan 2020]: exploratório no interesse em identificar agrupamentos de municípios com características semelhantes, e descritivo na caracterização das variáveis que compõem cada perfil e na comparação entre os dois cortes temporais.

Adota-se uma abordagem quantitativa, cuja sequência compreende a obtenção e organização das bases, a seleção de variáveis comparáveis entre os anos, a análise exploratória, o pré-processamento, a aplicação dos algoritmos de clusterização e a validação dos agrupamentos obtidos.

2.1. Área de estudo e recorte temporal

A unidade de análise são os 645 municípios do estado de São Paulo. A análise compreende dois cortes temporais, 2019 e 2024, tratados como observações distintas e não como uma série temporal contínua: o objetivo não é modelar a trajetória dos indicadores durante o período intermediário, mas comparar dois recortes específicos. Essa distinção é importante porque o período envolve uma mudança entre sistemas de informação e metodologias de coleta; assim, diferenças entre os anos devem ser interpretadas considerando também as características e limitações de cada fonte.

2.2. Fontes e harmonização dos dados

Os dados de 2019 provêm do Diagnóstico dos Serviços de Água e Esgotos do SNIS [Ministério do Desenvolvimento Regional 2021], organizado por prestador de serviço. Para São Paulo, os dados estão distribuídos em quatro planilhas de indicadores, segundo o tipo de prestador: regional (SABESP), local de direito público, local de empresa privada e local de direito privado com administração pública, somando 631 linhas e 628 municípios. Em três municípios (Mauá, Salto e Santa Maria da Serra), os serviços de água e de esgoto são prestados por entidades distintas; suas linhas foram combinadas para que cada município corresponda a uma única observação. Os dados de 2024 provêm das bases municipais de água e de esgoto do SINISA, ano de referência 2024 [Ministério das Cidades 2025]; utilizou-se a versão retificada da base de água (25/05/2026).

A harmonização compreendeu a padronização dos códigos municipais, a identificação dos indicadores correspondentes e a verificação da cobertura. O SNIS identifica os municípios pelo código do IBGE sem o dígito verificador (seis dígitos), enquanto o SINISA usa o código completo (sete dígitos); a junção foi feita removendo o último dígito do código do SINISA. A correspondência entre indicadores seguiu os glossários oficiais de indicadores dos dois sistemas.

O porte populacional foi obtido da população total residente informada no SINISA 2024 (variável DFE0001). Os municípios foram classificados em cinco faixas: até 20 mil habitantes (391 municípios), de 20 a 50 mil (116), de 50 a 100 mil (58), de 100 a 250 mil (46) e acima de 250 mil (34). Uma única referência populacional foi usada para os dois anos, de modo que mudanças de faixa não se confundam com mudanças de perfil. O porte não entra na formação dos agrupamentos; ele é usado posteriormente para caracterizar os perfis.

2.2.1. Indicadores selecionados

Foram selecionados quatro indicadores, dois relacionados ao acesso aos serviços e dois à qualidade e eficiência de sua prestação (Tabela 1). Todos são expressos em percentual.

Tabela 1. Indicadores selecionados e correspondência entre SNIS (2019) e SINISA (2024).

Variável	Dimensão	2019 (SNIS)	2024 (SINISA)
Água (atendimento total)	acesso	IN055	IAG0001
Esgoto (atendimento total)	acesso	IN056	IES0001
Tratamento do esgoto coletado	qualidade	IN016	IES2004
Perdas na distribuição	eficiência	IN049	IAG2013

A variável *água* representa o percentual da população total do município atendida por rede de abastecimento de água: em 2019, o Índice de Atendimento Total de Água (IN055); em 2024, o Atendimento da População Total com Rede de Abastecimento de Água (IAG0001).

A variável *esgoto* representa o percentual da população total atendida por rede coletora de esgoto: em 2019, o Índice de Atendimento Total de Esgoto Referido aos Municípios Atendidos com Água (IN056); em 2024, o Atendimento da População Total com Rede Coletora de Esgoto (IES0001). Essa variável refere-se à cobertura da rede coletora, e não ao tratamento.

A variável *tratamento* representa o percentual do esgoto coletado que recebe tratamento: em 2019, o Índice de Tratamento de Esgoto (IN016); em 2024, o indicador Esgoto Tratado Referido ao Esgoto Coletado (IES2004). Valor zero indica município que coleta esgoto sem tratá-lo.

A variável *perdas* representa o percentual do volume de água disponibilizado para distribuição que não é contabilizado como consumido: em 2019, o Índice de Perdas na Distribuição (IN049); em 2024, as Perdas Totais de Água na Distribuição (IAG2013).

Diferentemente das demais, valores mais altos indicam pior desempenho. A correspondência é declarada no glossário do SINISA, mas a composição dos volumes utilizados no cálculo apresenta pequenas diferenças entre os sistemas, o que torna esta a variável de comparabilidade mais frágil do conjunto.

Indicadores de resíduos sólidos (cobertura da coleta domiciliar e massa coletada per capita) foram avaliados e excluídos da matriz. Entre SNIS e SINISA, a cobertura da coleta passou de um conceito de coleta "regular" para coleta "direta ou indireta", e a massa per capita passou a ser calculada sobre a população total, e não mais sobre a população atendida. A correlação de Spearman entre os valores de 2019 e 2024 de um mesmo município foi de apenas 0,35 para a cobertura e 0,18 para a massa, contra 0,48 a 0,75 nos indicadores de água e esgoto. Além disso, a inclusão de resíduos reduziria a amostra de 607 para 521 municípios, com perda concentrada nos municípios de até 20 mil habitantes, dos quais apenas 77,2% teriam dados completos. Como o porte é uma das dimensões de interesse do trabalho, essa perda seletiva comprometeria a análise.

2.3. Análise exploratória dos dados

Antes da clusterização, os indicadores foram submetidos a uma análise exploratória, com o objetivo de compreender suas distribuições, identificar valores extremos e inconsistências e investigar as relações entre as dimensões dos serviços. Foram calculadas medidas de tendência central, dispersão e assimetria, a proporção de municípios no valor máximo (100%) e no zero, e as relações entre os indicadores foram avaliadas pela correlação de Spearman, que mede associações monotônicas sem pressupor relação linear.

Também foi realizada uma comparação exploratória entre 2019 e 2024 para cada indicador, considerando apenas os municípios com informação nos dois períodos. Foram examinadas a associação entre os valores dos dois anos e a proporção de municípios com valores superiores, inferiores ou iguais em 2024. Essa comparação não é interpretada diretamente como evidência de melhora ou piora, dadas as limitações de comparabilidade entre SNIS e SINISA.

2.4. Pré-processamento

A análise principal utiliza apenas os municípios com os quatro indicadores disponíveis nos dois anos (casos completos), sem imputação, evitando a introdução de informações artificiais que possam alterar a estrutura dos agrupamentos. Os municípios excluídos são descritos quanto ao porte, para avaliar o efeito da exclusão sobre a representatividade.

Dois problemas identificados na análise exploratória (Seção 4.2) receberam tratamento específico. O primeiro é o tratamento do esgoto de 129,42% registrado por Vinhedo em 2024, valor impossível para um percentual do esgoto coletado; ele foi limitado a 100%, valor coerente com o registrado pelo município em 2019 (99,71%). O segundo são os onze municípios com perdas na distribuição de exatamente 0% em 2019. Esses valores foram tratados como ausentes, pois são implausíveis em sistemas reais de distribuição e contraditos pelos próprios dados: os mesmos municípios registram perdas por ligação também nulas em 2019 e perdas entre 5% e 47% em 2024. Com isso, dez municípios deixam a amostra de casos completos (o décimo primeiro já não tinha informação de perdas em 2024).

Essas escolhas foram apoiadas por uma análise de cenários. Para cada problema, as alternativas (manter, limitar ou retirar o valor; e, para as perdas, também excluir a variável da matriz) foram combinadas em nove cenários, clusterizados com k-means em doze configurações de pré-processamento. Cada cenário foi comparado ao cenário sem tratamento pelo Índice de Rand Ajustado [Hubert e Arabie 1985]. O tratamento de Vinhedo praticamente não alterou os agrupamentos (ARI $\geq 0{,}98$ em todas as configurações). A retirada das perdas nulas também teve efeito pequeno na maioria das configurações, mas, com transformação logarítmica e padronização z-score, os dez valores nulos concentraram-se em um único grupo pequeno, que deixou de existir após sua retirada. A exclusão da variável de perdas foi o cenário que mais alterou os agrupamentos, indicando que ela carrega informação própria sobre a eficiência dos serviços; por isso, a variável foi mantida, e a matriz sem perdas é usada apenas como análise de sensibilidade.

As variáveis são padronizadas com um único ajuste sobre os dados de 2019 e 2024 empilhados, de modo que os dois cortes temporais fiquem no mesmo espaço e os perfis permaneçam comparáveis. Como os indicadores apresentam forte concentração no valor máximo de 100%, são comparadas alternativas de transformação e de padronização, avaliando-se o quanto cada escolha altera os agrupamentos.

2.5. Algoritmos de clusterização e validação

Serão comparados três algoritmos de agrupamento não supervisionado: k-means [MacQueen 1967], como método de particionamento; agrupamento hierárquico de Ward [Ward 1963]; e modelo de mistura gaussiana (GMM). Como os rótulos atribuídos pelos algoritmos são arbitrários, a comparação entre os resultados não é feita pela numeração dos clusters, mas pelas características das variáveis que compõem cada agrupamento.

A definição do número de clusters combina dois métodos. O primeiro é o Método da Silhueta [Rousseeuw 1987], avaliado em uma grade de valores de k (de 2 a 10). Para cada instância i, o coeficiente de silhueta é

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}}, \tag{1}$$

em que $a(i)$ é a distância média de i às demais instâncias do seu cluster e $b(i)$ é a menor distância média de i às instâncias de outro cluster. O método indica o valor de k que maximiza a média de $s(i)$ sobre todas as instâncias.

Outro método amplamente utilizado para determinar o número ideal de clusters é o Método do Cotovelo. Conforme [Nainggolan et al. 2019], o método envolve a análise da variação do Erro Quadrático Total (SSE) com diferentes valores de k:

$$\mathrm{SSE}(k) = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2, \tag{2}$$

em que C_j é o conjunto de instâncias do cluster j e μ_j é o seu centroide. O SSE diminui à medida que k aumenta; o número adequado de clusters corresponde ao ponto a partir do qual o aumento de k deixa de produzir reduções expressivas do SSE, formando um "cotovelo". Para evitar uma identificação apenas visual, o cotovelo é localizado como o

ponto da curva de SSE (de $k = 1$ a $k = 10$, com os dois eixos normalizados) mais distante da reta que liga seus extremos.

Os valores indicados pelos dois métodos são tratados como *candidatos*, avaliados por quatro critérios: (a) silhueta média superior a 0,25, limite abaixo do qual não há estrutura substancial de grupos [Kaufman e Rousseeuw 1990]; (b) estabilidade, medida pelo ARI médio entre a partição obtida com todos os dados e as partições de 100 reamostragens bootstrap de municípios, que deve ser de pelo menos 0,85; (c) menor cluster com pelo menos 5% das instâncias; e (d) caráter multivariado: a partição não pode ser reproduzida pelo agrupamento de uma única variável (ARI inferior a 0,90 entre a partição e o k-means aplicado a cada indicador isoladamente). O critério (d) evita adotar como perfil multivariado uma solução que equivale a classificar os municípios por um só indicador. É adotado o maior candidato que atende aos quatro critérios, por oferecer mais detalhe quando mais de um é adequado; os demais candidatos são descartados. As métricas de Calinski-Harabasz [Caliński e Harabasz 1974] e Davies-Bouldin [Davies e Bouldin 1979] complementam a avaliação da coesão e da separação dos grupos.

A concordância entre as soluções produzidas pelos diferentes algoritmos será avaliada pelo Índice de Rand Ajustado (ARI) [Hubert e Arabie 1985]. Adicionalmente, será empregada uma rotina de reamostragem bootstrap para verificar a estabilidade dos agrupamentos e uma análise da plausibilidade dos perfis, considerando os valores originais das variáveis.

2.6. Correspondência entre agrupamentos e porte

Para a comparação entre algoritmos e entre os dois cortes temporais, serão consideradas as características dos centroides ou parâmetros representativos de cada agrupamento, permitindo verificar quais perfis permanecem presentes ou se modificam entre 2019 e 2024. A comparação temporal será realizada a partir da composição dos perfis e da distribuição dos municípios nos agrupamentos de cada ano. Por fim, a distribuição dos perfis será analisada segundo as faixas de porte populacional.

O processamento é realizado em Python [Géron 2019], com as bibliotecas `pandas`, `NumPy`, `scikit-learn`, `SciPy`, `matplotlib` e `seaborn`. O código, incluindo a rotina de estabilidade por reamostragem, é disponibilizado junto aos procedimentos computacionais utilizados, de modo a favorecer a replicabilidade da análise.

3. Trabalhos Relacionados

A literatura sobre saneamento básico apresenta diferentes abordagens para identificar desigualdades territoriais e padrões associados à infraestrutura urbana. Para fundamentar a presente pesquisa, foram selecionados trabalhos que utilizam técnicas de agrupamento, análise estatística e construção de indicadores para investigar diferenças nas condições de saneamento em distintas escalas territoriais.

Um dos trabalhos mais diretamente relacionados à abordagem proposta investiga a relação entre saneamento básico e educação nos municípios brasileiros por meio de técnicas de clusterização. O estudo utiliza dados do Censo Demográfico de 2010 e aplica o algoritmo k-means para agrupar os municípios a partir de indicadores relacionados ao saneamento e à educação, identificando três grupos com diferentes características socioe-

conômicas. Entre as variáveis consideradas estão o acesso à água encanada, a coleta de lixo e indicadores associados à escolaridade [Lima e Moreira 2025].

A utilização do município como unidade de análise e de um método de aprendizado não supervisionado aproxima esse estudo da proposta desenvolvida neste trabalho, e demonstra como a clusterização pode revelar padrões que não são facilmente observados na análise isolada dos indicadores. Entretanto, o estudo utiliza somente informações do Censo de 2010 e combina variáveis de saneamento com indicadores educacionais. A presente pesquisa diferencia-se ao concentrar a formação dos agrupamentos em indicadores dos serviços de água e esgoto, ao comparar dois recortes temporais com dados municipais do SNIS e do SINISA e ao considerar diferentes métodos de agrupamento.

Outra perspectiva é apresentada no estudo sobre as condições de saneamento e as desigualdades de cor ou raça no Brasil urbano. A pesquisa utiliza microdados do Censo Demográfico de 2010 e considera como desfechos o abastecimento de água, o esgotamento sanitário, a coleta de lixo e uma medida de saneamento adequado. A análise combina estatísticas descritivas com modelos de regressão logística múltipla ajustados por características socioeconômicas e demográficas. Os resultados indicam que o esgotamento sanitário apresentava as condições mais precárias entre os serviços analisados e evidenciam desigualdades na disponibilidade de infraestrutura sanitária, especialmente para domicílios com responsáveis indígenas [Raupp et al. 2017].

Embora não utilize técnicas de clusterização, esse estudo é relevante por demonstrar que indicadores de saneamento devem ser analisados de maneira multidimensional, uma vez que diferentes componentes da infraestrutura podem apresentar níveis de cobertura distintos. Sua unidade de análise, entretanto, é o domicílio, enquanto a presente pesquisa considera o município. Além disso, o estudo utiliza um único recorte temporal, enquanto a análise aqui proposta compara 2019 e 2024.

Uma abordagem territorial mais específica é encontrada na construção do *Urban Health Index* (UHI) para o município de São Paulo. Nesse estudo, foram utilizados dados do Censo Demográfico de 2010 no nível de setor censitário, considerando sete indicadores relacionados ao acesso a esgoto, coleta regular de resíduos, disponibilidade de banheiros, abastecimento de água, renda, composição demográfica e alfabetização. Após a padronização, os indicadores foram agregados em uma única medida e espacializados, possibilitando a identificação de desigualdades intraurbanas [Lima et al. 2022]. Os resultados revelaram diferenças expressivas entre os setores censitários, com razão de disparidade de 2,95 e coeficiente angular de 0,30, e um padrão de desigualdade entre áreas centrais e periféricas [Lima et al. 2022].

Apesar dessa contribuição, o objetivo do UHI é sintetizar diferentes dimensões em um único índice, enquanto a presente pesquisa busca preservar a natureza multivariada dos indicadores para identificar grupos de municípios. Além disso, a escala territorial é distinta: o UHI evidencia desigualdades entre setores censitários dentro do município de São Paulo, e este trabalho considera os 645 municípios do estado.

Em conjunto, os trabalhos analisados demonstram a relevância de abordagens quantitativas e multivariadas para a identificação de desigualdades relacionadas ao saneamento, mas diferem quanto à unidade territorial, às variáveis, às técnicas e ao período analisado. A presente pesquisa busca avançar nessa direção ao utilizar indicadores mu-

nicipais de acesso, qualidade e eficiência dos serviços de água e esgoto para identificar perfis por meio de diferentes técnicas de clusterização, em dois momentos distintos e considerando, com as devidas ressalvas, a transição entre o SNIS e o SINISA.

4. Resultados Preliminares

Os resultados a seguir referem-se à análise exploratória dos dados municipais de água e esgoto do SNIS (2019) e do SINISA (2024). A Tabela 2 exemplifica a estrutura da base consolidada para cinco municípios.

Tabela 2. Exemplo da estrutura dos dados utilizados (valores em %).

	2019 – SNIS				2024 – SINISA			
Município	Água	Esgoto	Trat.	Perdas	Água	Esgoto	Trat.	Perdas
São Paulo	99,30	96,30	92,20	34,38	99,98	99,26	88,89	24,46
Campinas	98,09	94,66	89,25	20,70	99,80	96,61	94,03	17,46
Santos	100,00	99,93	100,00	11,94	99,33	98,46	100,00	5,35
Sorocaba	98,49	98,22	97,50	36,21	98,97	98,85	97,62	34,22
Presidente Prudente	100,00	99,61	100,00	28,90	100,00	100,00	100,00	22,38

4.1. Disponibilidade dos dados

Dos 645 municípios, 628 têm os quatro indicadores em 2019 e 618 em 2024. Os 17 municípios sem dados em 2019 não constam em nenhuma planilha de água e esgoto do SNIS daquele ano. Em 2024, a principal causa de ausência é o atendimento de esgoto, sem valor para 27 municípios, por ausência na base ou por o indicador não ter sido calculado. No total, 607 municípios (94,1%) têm os quatro indicadores nos dois anos. Após a retirada das perdas nulas de 2019 (Seção 2.4), a amostra da análise principal reúne 597 municípios (92,6%).

Os 48 municípios fora da amostra são menores que os incluídos (mediana de 9,8 mil contra 14,1 mil habitantes): 36 têm até 20 mil habitantes, e nenhum tem mais de 250 mil. Ainda assim, a proporção de municípios na amostra é alta em todas as faixas de porte (Tabela 3), de modo que a exclusão tem efeito limitado sobre a representatividade por porte.

Tabela 3. Municípios por faixa de porte: total, com os quatro indicadores nos dois anos (completos) e na amostra final, após a retirada das perdas nulas de 2019.

Faixa de porte (habitantes)	Total	Completos	Amostra final	% na amostra
Até 20 mil	391	363	355	90,8
20 a 50 mil	116	110	108	93,1
50 a 100 mil	58	56	56	96,6
100 a 250 mil	46	44	44	95,7
Acima de 250 mil	34	34	34	100,0
Total	645	607	597	92,6

4.2. Distribuição dos indicadores

A Figura 1 apresenta os histogramas dos quatro indicadores em 2019 e 2024. As estatísticas desta seção referem-se aos dados originais, antes dos tratamentos descritos na Seção 2.4.

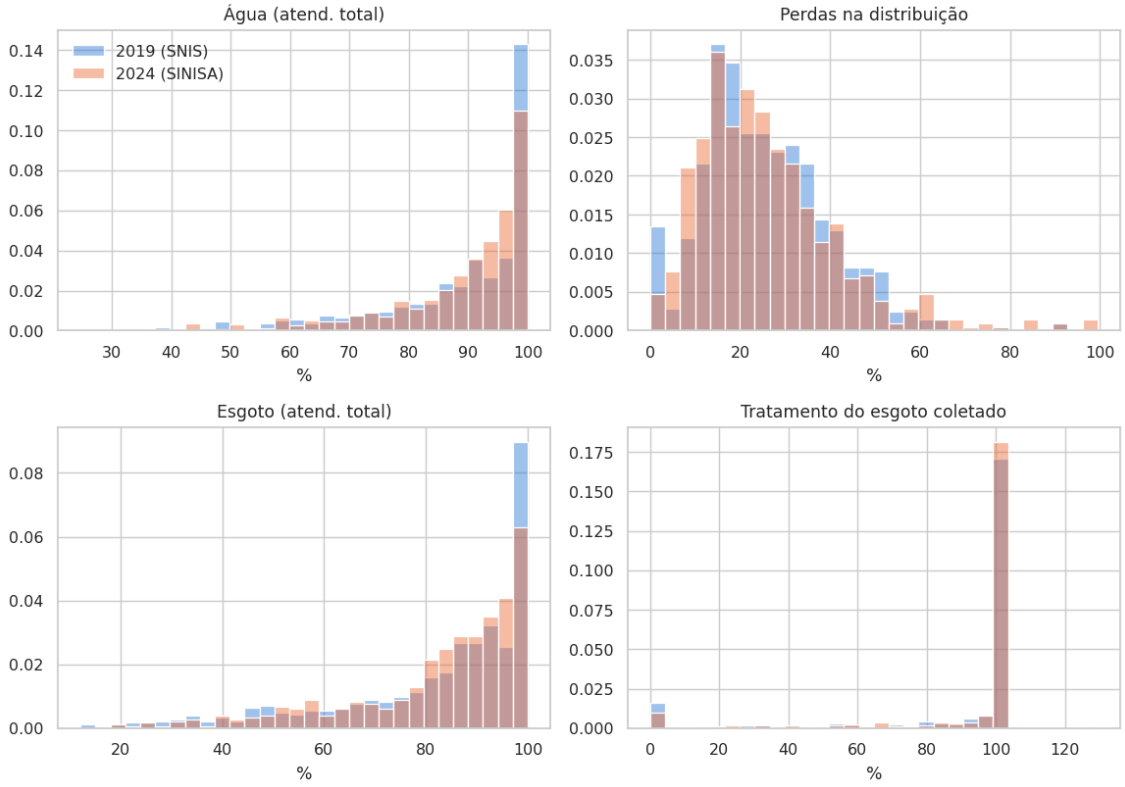


Figura 1. Distribuição dos indicadores em 2019 (SNIS) e 2024 (SINISA).

Os indicadores de atendimento de água e de esgoto concentram-se nas faixas mais elevadas nos dois anos. No atendimento de água, a mediana foi de 93,05% em 2019 e 93,20% em 2024, e as médias, de 88,34% e 88,92%. Há, porém, municípios com percentuais consideravelmente inferiores, com mínimos de 26,82% em 2019 e 24,77% em 2024. A proporção de municípios com atendimento de 100% caiu de 22,93% para 11,98%, o que pode refletir tanto mudanças reais quanto a mudança da base populacional usada no cálculo.

O atendimento de esgoto apresenta maior dispersão. A média passou de 81,90% para 82,51%, e as medianas foram de 88,69% e 87,88%. Os mínimos foram de 12,17% em 2019 e 16,91% em 2024. A distância entre os menores valores e a concentração nas faixas superiores evidencia a heterogeneidade dos municípios paulistas nessa dimensão.

O tratamento do esgoto coletado apresenta a distribuição mais concentrada: a mediana é de 100% nos dois anos, e 71,97% dos municípios em 2019 e 76,97% em 2024 tratam todo o esgoto coletado. No extremo oposto, 43 municípios em 2019 e 22 em 2024 coletam esgoto sem tratá-lo (valor zero). Esse padrão caracteriza um efeito de teto acentuado e uma distribuição praticamente bimodal. Em 2024, o município de Vinhedo apresenta valor de 129,42%, fisicamente impossível para um percentual do esgoto coletado, que foi limitado a 100% antes da clusterização (Seção 2.4).

As perdas na distribuição têm comportamento distinto, com assimetria à direita. A mediana foi de 24,16% em 2019 e 23,08% em 2024, e as médias, de 25,52% e 26,03%. Enquanto 95% dos municípios apresentam perdas de até 50,20% (2019) e 58,10% (2024), há valores extremos: sete municípios, seis deles com até 20 mil habitantes, têm perdas iguais ou superiores a 85% em 2024, chegando a 99,46%. Em 2019, onze municípios registram perdas de exatamente 0%, valor implausível em sistemas reais de distribuição, que foi tratado como ausente (Seção 2.4). As perdas elevadas de 2024 permanecem na análise, por serem possíveis, mas devem ser verificadas, pois observações extremas podem influenciar métodos baseados em distância, como o k-means.

4.3. Relações entre os indicadores

A Figura 2 apresenta as matrizes de correlação de Spearman de 2019 e 2024.



Figura 2. Correlação de Spearman entre os indicadores em 2019 e 2024.

A associação mais elevada nos dois períodos ocorre entre os atendimentos de água e de esgoto, com $\rho = 0{,}82$ em 2019 e $\rho = 0{,}78$ em 2024: municípios com atendimento de água relativamente elevado tendem a apresentar também atendimento de esgoto elevado.

Os indicadores de qualidade e eficiência, por outro lado, são praticamente independentes dos indicadores de acesso. As correlações das perdas com o atendimento de água e de esgoto ficaram entre $-0{,}08$ e $0{,}06$ nos dois anos, e as do tratamento com essas variáveis, entre $-0{,}13$ e $-0{,}02$. A associação mais forte entre os dois indicadores de qualidade e eficiência foi negativa e fraca, entre perdas e tratamento ($\rho = -0{,}20$ em 2019 e $-0{,}24$ em 2024).

Esses resultados indicam que os quatro indicadores não representam uma única dimensão: o acesso aos serviços não determina a qualidade de sua prestação. Municípios com atendimento semelhante podem diferir quanto ao tratamento do esgoto e às perdas, o que reforça o interesse em uma abordagem multivariada.

4.4. Comparação entre 2019 e 2024

A Figura 3 apresenta os valores de cada município em 2019 (eixo horizontal) e 2024 (eixo vertical), considerando os municípios com informação nos dois anos. A linha tracejada representa a igualdade entre os períodos. A Tabela 4 resume a comparação.

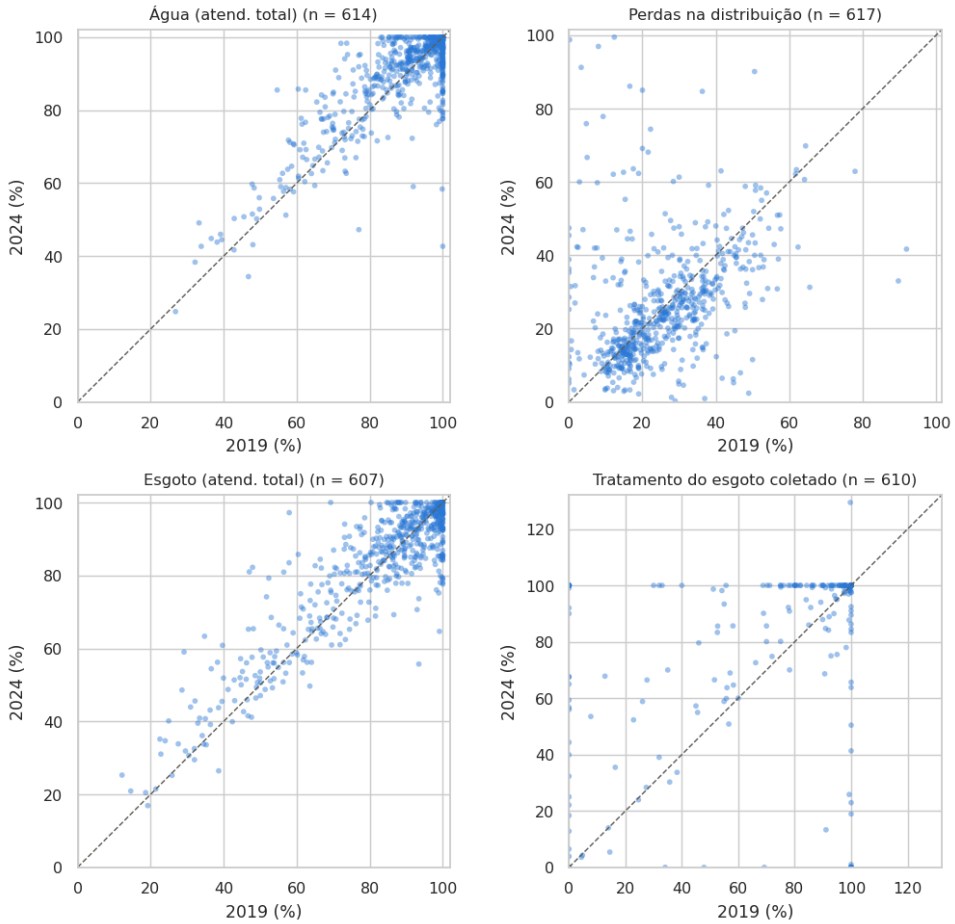


Figura 3. Valores dos indicadores em 2019 e 2024 para os municípios com dados nos dois anos.

O atendimento de esgoto apresentou a maior associação entre os dois períodos ($\rho = 0{,}75$), seguido pelo tratamento ($\rho = 0{,}67$) e pelo atendimento de água ($\rho = 0{,}63$), indicando manutenção da posição relativa dos municípios nessas dimensões. As perdas apresentaram a menor associação ($\rho = 0{,}48$), resultado coerente com a maior fragilidade da correspondência entre os dois sistemas para esse indicador.

Nos atendimentos de água e esgoto, a proporção de municípios com aumento foi pouco superior à de redução (51,95% contra 42,02% em água e 51,89% contra 46,95% em esgoto). No tratamento, 70,98% dos municípios mantiveram o mesmo valor, quase sempre 100%, e entre os demais predominou o aumento. Nas perdas, 61,91% dos municípios apresentaram valores menores em 2024.

Esses resultados não devem ser interpretados diretamente como evidência de melhora ou piora dos serviços. A comparação envolve a transição do SNIS para o SINISA, com diferenças na estrutura, nas definições e nos procedimentos de produção das informações; as diferenças observadas podem refletir tanto alterações efetivas nos municípios quanto mudanças metodológicas.

Tabela 4. Comparação dos indicadores entre 2019 e 2024 para os municípios com dados nos dois períodos. Aumento, redução e igual referem-se ao valor de 2024 em relação ao de 2019.

Indicador	N	Aumento (%)	Redução (%)	Igual (%)	ρ
Água	614	51,95	42,02	6,03	0,63
Esgoto	607	51,89	46,95	1,15	0,75
Tratamento do esgoto	610	19,84	9,18	70,98	0,67
Perdas	617	37,93	61,91	0,16	0,48

4.5. Agrupamentos preliminares com k-means

Como primeiro resultado da etapa de clusterização, o k-means foi aplicado aos 597 municípios nos dois anos (1.194 municípios-ano), com padronização robusta ajustada sobre 2019 e 2024 em conjunto e transformação logarítmica com winsorização. Essa configuração de pré-processamento ainda é provisória. O Método da Silhueta indicou $k = 2$ e o Método do Cotovelo, $k = 3$. A Tabela 5 apresenta a avaliação dos dois candidatos.

Tabela 5. Avaliação dos candidatos a número de clusters (k-means, 1.194 municípios-ano).

Candidato	Silhueta (a)	Estabilidade (b)	Menor cluster (c)	Uma variável (d)	Resultado
$k = 2$ (Silhueta)	0,476	0,989	19,3%	0,965	descartado (d)
$k = 3$ (Cotovelo)	0,367	0,947	18,1%	0,385	adotado

Os dois candidatos atendem aos critérios de estrutura, estabilidade e tamanho mínimo, mas a solução com $k = 2$ é quase integralmente reproduzida pelo agrupamento do indicador de tratamento do esgoto (ARI de 0,965): ela separa os municípios que tratam praticamente todo o esgoto coletado dos demais. Por isso, foi descartada. A solução com $k = 3$ atende aos quatro critérios e foi adotada. Ela preserva a separação por tratamento e acrescenta a dimensão de acesso: os municípios que tratam todo o esgoto coletado dividem-se em dois grupos segundo o nível de acesso às redes (Figura 4 e Tabela 6).

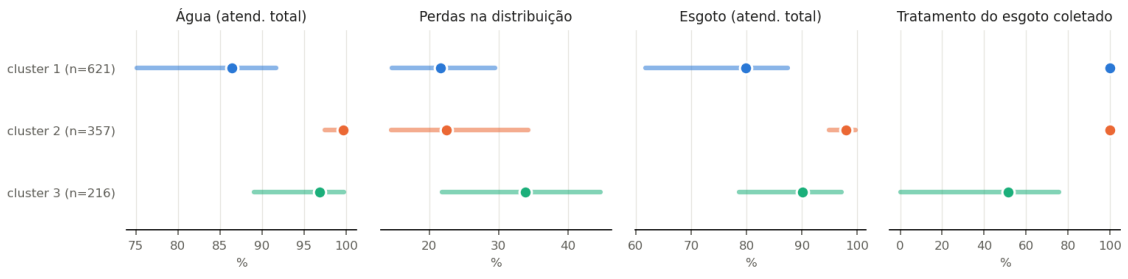


Figura 4. Perfis dos três clusters: mediana (ponto) e intervalo interquartil (barra) de cada indicador, em unidades originais (1.194 municípios-ano).

O cluster 1 reúne municípios que tratam todo o esgoto coletado, mas com acesso intermediário às redes de água e de esgoto. O cluster 2 combina acesso quase universal e tratamento total. O cluster 3 apresenta bom acesso, porém tratamento parcial ou ausente

Tabela 6. Perfis dos três clusters: mediana e intervalo interquartil (%), número de municípios por ano e distribuição por faixa de porte (% dos municípios-ano de cada faixa).

	Cluster 1	Cluster 2	Cluster 3
Água	86,4 [75,1–91,6]	99,7 [97,5–100]	96,8 [89,0–99,7]
Esgoto	79,8 [61,8–87,5]	97,9 [94,9–99,7]	90,0 [78,7–97,1]
Tratamento	100 [100–100]	100 [100–100]	51,4 [0,0–75,6]
Perdas	21,7 [14,7–29,5]	22,5 [14,5–34,3]	33,8 [21,8–44,7]
Municípios 2019 / 2024	306 / 315	176 / 181	115 / 101
Até 20 mil	66,5	24,2	9,3
20 a 50 mil	41,7	36,1	22,2
50 a 100 mil	32,1	36,6	31,2
100 a 250 mil	19,3	44,3	36,4
Acima de 250 mil	8,8	39,7	51,5

e perdas maiores. A distribuição por porte é graduada: o cluster 1 concentra 66,5% dos municípios-ano de até 20 mil habitantes e apenas 8,8% dos acima de 250 mil, enquanto o cluster 3 segue o padrão inverso (9,3% e 51,5%). Entre 2019 e 2024, 429 dos 597 municípios permaneceram no mesmo cluster; os demais se dividem entre mudanças em várias direções, como 50 municípios que passaram do cluster 1 para o 2 e 54 que fizeram o caminho inverso.

A silhueta média da solução adotada (0,367), assim como a do candidato descartado (0,476), situa-se na faixa que [Kaufman e Rousseeuw 1990] associam a estrutura fraca, o que indica que os perfis devem ser lidos como tendências, e não como grupos nitidamente separados. Esses resultados são preliminares e ainda serão comparados com o agrupamento hierárquico de Ward e o modelo de mistura gaussiana.

5. Discussão e conclusão

A análise exploratória evidencia que os serviços de água e esgoto dos municípios paulistas apresentam comportamentos distintos conforme a dimensão observada. Os indicadores de acesso concentram-se em níveis elevados, mas com dispersão e municípios bem abaixo do conjunto principal, especialmente no esgoto. O tratamento do esgoto coletado é majoritariamente total, mas um grupo de municípios coleta sem tratar, e as perdas variam amplamente.

A forte associação entre atendimento de água e de esgoto indica que essas dimensões compartilham parte importante de sua estrutura, enquanto a independência do tratamento e das perdas em relação ao acesso mostra que a situação dos serviços não pode ser representada por uma única dimensão. Esse resultado sustenta o uso de técnicas multivariadas de clusterização.

Na comparação entre 2019 e 2024, os indicadores de acesso e de tratamento mantiveram de forma razoável a posição relativa dos municípios, enquanto as perdas apresentaram menor associação temporal. Essas diferenças devem ser interpretadas com cautela, uma vez que os dois períodos provêm de sistemas de informação distintos.

A análise também identificou problemas nos dados. O valor impossível de Vin-

hedo no tratamento em 2024 foi limitado a 100%, e as perdas nulas de 2019 foram tratadas como ausentes, o que reduziu a amostra a 597 municípios. A análise de cenários mostrou que a primeira decisão não altera os agrupamentos e que a segunda evita, em parte das configurações, a formação de um grupo artificial. Permanecem como pontos de atenção o efeito de teto no atendimento de água e, sobretudo, no tratamento do esgoto, e as perdas acima de 85% em 2024.

Os agrupamentos preliminares com k-means reforçam essa leitura. A solução adotada, com três perfis, separa os municípios tanto pelo acesso às redes quanto pelo tratamento do esgoto, e o perfil de acesso intermediário concentra-se nos municípios menores. Já a solução com dois grupos, preferida pela silhueta, equivale praticamente a uma classificação pelo tratamento do esgoto e foi descartada, o que mostra a importância de usar critérios adicionais à silhueta na escolha do número de clusters. A estrutura de grupos é, contudo, fraca, e os perfis devem ser confirmados com outros algoritmos e configurações de pré-processamento.

As próximas etapas consistem na definição final da transformação e da padronização dos indicadores, seguidas da aplicação dos métodos k-means, agrupamento hierárquico de Ward e GMM. Os agrupamentos serão avaliados quanto à qualidade e à estabilidade e caracterizados quanto ao porte populacional. Por fim, os perfis de 2019 e 2024 serão comparados, considerando as limitações de comparabilidade entre SNIS e SINISA.

Referências

Caliński, T. e Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1):1–27.

Davies, D. L. e Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2):224–227.

Gil, A. C. (2017). *Como elaborar projetos de pesquisa*. Atlas, São Paulo. 6. ed.

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O'Reilly Media, Sebastopol. 2. ed.

Hubert, L. e Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1):193–218.

Kaufman, L. e Rousseeuw, P. J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley, New York.

Lima, O. A. C. P., Kruger, E., e Tennant, M. (2022). São Paulo urban health index: measuring and mapping health disparities. *Revista Brasileira de Epidemiologia*, 25:e220005.

Lima, P. e Moreira, M. (2025). Saneamento e educação: Explorando padrões em municípios brasileiros através de clusterização. In *XIII Simpósio de Engenharia de Produção*.

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297.

Ministério das Cidades (2025). Resultados SINISA 2025 – ano de referência 2024. https://www.gov.br/cidades/pt-br/acesso-a-informacao/acoes-e-programas/saneamento/sinisa/resultados-sinisa/resultados-sinisa-2025. Planilhas publicadas em 18/12/2025; base de água retificada em 25/05/2026. Acesso em: 24 out. 2026.

Ministério do Desenvolvimento Regional (2021). Diagnóstico dos Serviços de Água e Esgotos – 2019 (25º Diagnóstico do SNIS). https://www.gov.br/mdr/pt-br/assuntos/saneamento/snis/diagnosticos-anteriores-do-snis/agua-e-esgotos-1/2019. Republicação de 31/03/2021. Acesso em: 24 out. 2026.

Mohajan, H. K. (2020). Quantitative research: A successful investigation in natural and social sciences. *Journal of Economic Development, Environment and People*, 9(4):52–79.

Nainggolan, R., Perangin-angin, R., Simarmata, E., e Tarigan, A. F. (2019). Improved the performance of the K-Means cluster using the sum of squared error (SSE) optimized by using the elbow method. *Journal of Physics: Conference Series*, 1361(1):012015.

Raupp, L. et al. (2017). Condições de saneamento e desigualdades de cor/raça no Brasil urbano: uma análise com foco na população indígena com base no Censo Demográfico de 2010.

Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301):236–244.